

크레이지 아케이드 강화학습 에이전트 개발 프로젝트

DQN과 PPO 알고리즘을 활용한 2인 대전 환경의 AI 개발 및 분석



알고리즘 분석



학습 결과



문제 해결

과목명: 강화학습의 기초

제출자: 정희식

학 번 : A72080

제출일: 2025년 12월 6일

프로젝트 개요 및 연구 목표

💡 프로젝트 개요

크레이지 아케이드와 유사한 2인 대전 환경에서 DQN(Deep Q-Network)과 PPO(Proximal Policy Optimization) 강화학습 에이전트를 설계하고 분석하는 것을 목표로 합니다. 복잡한 게임 환경에서 에이전트가 다음과 같은 복합적인 전략을 스스로 학습하도록 합니다.

🎯 연구 목표

🧠 알고리즘 개발

효과적인 전략 학습을 위해 DQN과 PPO 알고리즘을 적절히 조정하고 개선합니다.

📈 학습 분석

알고리즘의 학습 과정에서 나타나는 특징과 문제점을 심층적으로 분석합니다.

♟️ 학습 시도하는 복합적 전략



맵 탐색 및 아이템 획득
효율적인 맵 탐색과 아이템 수집 전략을 학습



적절한 위치에 물풍선 설치
전략적인 물풍선 배치로 상대방의 이동을 제한



상대방을 물풍선에 가두어 KO시키기
적의 움직임을 제약하고 기회를 노려 승리 조건 달성

시스템 설계 및 아키텍처



C++ 게임 서버

- 게임 로직 처리
- 맵 및 충돌 처리
- 아이템 및 물품선 처리

TCP 소켓 통신
JSON 형식 상태 전송
정수 형식 행동 수신



Python 강화학습 에이전트

- 학습 알고리즘 구현
- 행동 선택 로직
- 플레이어 컨트롤



상호작용 방식

TCP 소켓 통신을 통해 에이전트는 각 스텝마다 게임 상태를 JSON 형태로 받아보고, 행동을 결정하여 정수 형태로 전송



전체 시스템 구조

C++로 구현된 실제 게임 로직과 Python으로 구현된 학습 알고리즘이 상호작용하며 복합적 전략을 학습하도록 구성



학습 및 실행 모드

학습 모드에서는 환경과의 상호작용을 통해 모델을 업데이트 하고, 평가 모드에서는 학습된 모델을 사용하여 실제 플레이

상태, 행동, 보상 정의

📍 상태 (State)

607차원의 벡터로 정의되며, 총 4가지 카테고리로 구성됩니다:

- 플레이어 정보 (9차원)
- 적 정보 (9차원)
- 폭탄 위치 (195차원)
- 아이템 위치 (195차원)
- 물줄기 위치 (195차원)
- 게임 메타 정보 (4차원)

i 상세 항목: 위치, 속도, 폭탄 수, 파워, 상태, 생존 여부, 감힘 정보 등

총 607차원

🖐️ 행동 (Action)

에이전트가 환경에 가할 수 있는 총 6가지 행동:

- 0 IDLE
(제자리 대기)
- 1 UP
(위쪽 이동)
- 2 DOWN
(아래쪽 이동)
- 3 LEFT
(왼쪽 이동)
- 4 RIGHT
(오른쪽 이동)
- 5 PLACE BOMB
(물풍선 설치)

🏆 보상 (Reward)

에이전트의 행동에 대한 피드백으로, 다양한 상황에 따라 다음과 같은 보상이 부여됩니다:

- +** 아이템 관련 보상
아이템 획득 (5.0~20.0)
- +** 공격 및 승리 보상
적을 물풍선에 가두기 (50.0)
적 직접 터뜨리기 (200.0)
최종 승리 (300.0)
- 피해 및 사망 페널티
물풍선에 갇힘 (-60.0)
터짐 (-120.0~-90.0)
최종 패배 (-300.0)

DQN 에이전트 구조 및 학습 방식

DQN 개요

DQN(Deep Q-Network)은 가치 기반(Value-based) 강화학습 알고리즘으로, 특정 상태에서 각 행동을 취했을 때 얻을 수 있는 최대 보상(Q-value)을 예측하는 신경망을 학습합니다.

학습 과정

- ✓ ϵ -greedy 정책을 사용하여 탐험(Exploration)과 활용(Exploitation)의 균형을 맞춥니다.
- ✓ 경험 리플레이(Replay Memory)를 통해 학습 데이터의 상관관계를 줄이고 학습 안정성을 높입니다.
- ✓ Double DQN 기법을 통해 Q-value의 과대평가 문제를 완화하여 학습 안정성을 향상시킵니다.

핵심 구성 요소

 손실 함수

예측된 Q-value과 타겟 Q-value 간의 MSE(Mean Squared Error) 손실을 최소화

 ϵ -greedy


초기에는 높은 ϵ 값으로 탐험, 학습이 진행되면서 ϵ 값을 감소

CNN-Sensor 융합 신경망 구조



PPO 에이전트 구조 및 학습 방식

Actor-Critic 신경망 구조



핵심 구성 요소

- 마지막 레이어 가중치를 작게 초기화하여 모든 행동의 확률을 균등하게 시작
- Actor: 512→256→6 완전 연결 계층 + 소프트맥스 활성화
- Critic: 512→256→1 완전 연결 계층

정책 기반 학습 및 학습 방식

행동 선택 방식

- | 학습 중 (training=True) | 평가 시 (training=False) |
|-----------------------------------|-----------------------------|
| Actor가 출력한 행동 확률 분포에서 샘플링하여 탐험 포함 | 가장 확률이 높은 행동만을 선택하는 결정론적 정책 |

GAE(Generalized Advantage Estimation)

에피소드가 종료된 후, 저장된 경험들을 바탕으로 Advantage 값을 계산합니다.

$$\text{Advantage} = \text{행동 가치} - \text{상태 가치 추정치}$$

에이전트가 특정 행동을 선택하는 것이 평균적으로 얼마나 유리한지를 나타냅니다.

PPO 특징

- 정책 기반 알고리즘으로, 정책 자체를 직접 학습
- 클리핑(Clippping) 기법을 사용하여 정책 업데이트 폭 제한
- 에피소드 종료 후 GAE를 사용하여 보상 신호를 보정
- 행동 선택 시 탐험과 활용의 균형을 맞춤

실험 환경 및 하이퍼파라미터

환경 설정

핵심 구성 요소

- State Dimension: 607 (Flattened Vector including Map, Enemies, Bombs)
- Action Space: 6 Discrete Actions (Idle, Up, Down, Left, Right, Place Bomb)
- Max Episodes: 1,000
- Communication: TCP Socket (C++ Server – Python Agent)

Algorithm 하이퍼파라미터

Parameter	DQN (Value-based)	PPO (Policy-based)	Note
Learning Rate	1e-4 -> 5e-4	5e-4	튜닝을 통해 학습 속도 최적화
Discount Factor (γ)	0.99	0.99	장기적 보상(Long-term Reward) 중시
Buffer / Batch	Memory: 100,000 / Batch: 64	Batch: 64 / Epochs: 10	DQN Experience Replay 용량 증대
Exploration	e-greedy (Decay 0.9995)	Entropy Coef: 0.02	PPO 탐험 강제 (Default 0.01 -> 0.02)

실험 결과: DQN vs PPO 행동 패턴 차이



DQN 에이전트

✂ 다양한 탐험 행동

학습 후에도 일정 확률로 다양한 행동을 시도하며, 특정 행동에 고착되지 않음

🔍 활용(Utility) 행동

Q-value를 기반으로 최적의 행동을 추론하며, 가치 기반 알고리즘의 특성을 가짐

⚖ ϵ -greedy 탐험 정책

학습 초기에는 높은 ϵ 값으로 무작위 탐험을 수행, 점진적으로 최적 행동 선택 비중 증가



PPO 에이전트

🛑 제자리 멈춤 행동

"IDLE" 행동에 고착되어 움직임을 멈추며, 위험을 회피하는 안전한 선택으로 판단됨

💀 자폭 행동

폭탄 설치 후 회피하지 못하고 자폭하는 행동이 반복됨, 큰 음의 보상을 초래

🎯 결정론적 행동 선택

평가 시에는 학습된 확률 분포에서 가장 높은 확률을 가진 행동만을 선택함

결과 분석 1: DQN의 꾸준한 탐험 원리


✂ ϵ -greedy 탐험 정책

- 학습 초기에는 높은 ϵ 값으로 무작위 행동(탐험)을 많이 수행
- 학습이 진행될수록 ϵ 값을 점진적으로 감소
- 하지 실제 코드에서는 ϵ 값을 완전히 0으로 만들지 않고 작은 값으로 유지
- 결과적으로 학습 후에도 일정 확률로 항상 무작위 행동이 섞여 남음

⚖ 유사한 Q-value 상황에서의 행동 선택

- 여러 행동의 Q-value가 비슷한 상황이 자주 발생
- DQN은 Q-value가 가장 높은 행동을 선택
- 학습 과정에서의 노이즈나 파라미터 업데이트의 미세한 차이로 인해
- Q-value가 근소하게 높은 행동이 계속 바뀌어짐
- 이로 인해 특정 행동에 완전히 고착되지 않고 다양한 행동을 보임

DQN 행동 패턴 시뮬레이션 시간 개념도



💡 핵심 분석

- ✓ DQN은 가치 기반(Value-based) 알고리즘으로, Q-value을 학습하여 최적의 행동을 간접적으로 추론
- ✓ 학습 초반: 다양한 행동 패턴 생성 → 학습 후: 세밀한 확률 변화에서 자발적 행동 유지
- ✓ ϵ -greedy 정책과 Q-value 변동이 DQN 다양한 행동 패턴 형성의 주요 원인

결과 분석 2: PPO의 결정론적 수렴 문제

⚠ PPO의 결정론적 행동 선택

- ✓ PPO는 정책 기반(Policy-based) 알고리즘으로, Actor 네트워크가 행동 확률 분포를 학습
- ✓ 학습 중에는 샘플링(Sampling)을 통해 탐험 수행
- ✓ 평가/플레이 시에는 결정론적 정책(Argmax) 사용

🎯 수렴 메커니즘

- ✓ 특정 행동의 확률이 빠르게 증가하면서 다른 행동의 확률이 줄어듦
- ✓ 클리핑 메커니즘으로 인해 정책의 급격한 변화 제한
- ✓ 학습이 진행될수록 하나의 행동으로 수렴하는 경향 발생


🛑 "제자리 멈춤"(IDLE)

안전한 선택으로 인식되면 확률이 급격히 높아지고, 한번 고착되면 다른 행동 시도가 사라짐

💀 "자폭" 행동

폭탄 설치 후 회피하지 못하고 자폭하는 행동이 반복되면, 폭탄 설치 행동의 확률이 극도로 낮아짐

정책 수렴 메커니즘 시각화



환경 특성이 알고리즘에 미친 영향

🎮 게임 환경의 특성

🏆 희소한 최종 보상

- '상대방 KO'나 '승리'와 같은 최종 목표 달성 보상은 매우 크지만,
- 이러한 이벤트는 게임 플레이 중 드물게 발생함
- '크레이지 아케이드' 환경의 주요 특징

⚠️ 즉각적인 큰 페널티

- '사망'이나 '위험 구역 진입'과 같은 행동은
- 즉각적이고 큰 음의 보상을 초래함
- 에이전트가 '안전지향적'인 행동을 유도함

🔗 알고리즘 반응

🤖 DQN 에이전트

- ϵ -greedy 정책 덕분에 학습이 진행된 후에도 일정 수준의 무작위 탐험 유지
- 지역 최적해에 갇힐 위험이 상대적으로 적음
- 다양한 행동을 시도하며 더 넓은 범위의 전략을 탐색함

✓ 다양한 행동 패턴

🧠 PPO 에이전트

- 정책 기반 알고리즘으로, 클리핑 메커니즘을 사용하여 정책의 급격한 변화 제한
- 평가 시에는 결정론적 행동 선택 (샘플링 없음)
- 큰 페널티를 피하는 '안전한' 행동에 빠르게 수렴함

! 비정상적 행동 고착

💡 환경의 희소한 보상 구조와 즉각적 페널티는 PPO의 결정론적 행동 선택에 악영향을 주어, DQN보다 '캠핑'이나 '자폭'과 같은 비정상적인 행동 패턴을 보이게 했습니다.

문제 해결 과정 및 개선사항



아이템 맵 인덱스 버그 수정

❗ 문제점

초기 `game_interface.py`의 `_dict_to_vector` 함수에서 아이템 획득 보상을 계산할 때 `map_items` 대신 `map_bombs` 인덱스를 잘못 참조

✅ 해결

`map_items`를 정확한 인덱스 범위로 수정:
`map_items = self.current_state[18+195:18+195*2]`

📈 영향

에이전트가 아이템 근처로 이동할 때 올바른 보상을 받게 되어 아이템 획득 전략 학습이 강화됨



승패 기록 불일치 해결

❗ 문제점

C++ 서버에서 `winner=2`를 보냈음에도 불구하고 Player 1(DQN) 측에서 `player_index=1`일 경우 승리로 처리되는 경우가 발생

✅ 해결

승패 판단 로직을 단순화: `winner == player_index`일 경우 승리, `winner == 0`일 경우 무승부, 그 외에는 패배

📈 영향

1대1 게임 환경에서 한쪽이 승리하면 다른 한쪽은 반드시 패배하거나 무승부가 되는 일관된 승패 기록 가능



PPO 비정상 행동 완화를 위한 보상 셰이핑

❗ 문제점

PPO 에이전트가 '제자리 멈춤'이나 '자폭'과 같은 비정상적인 행동에 고착되는 문제

✅ 보상 설계 개선

- ❌ 연속 IDLE 페널티: 5스텝 이상 IDLE 시 -3.0 보상
- ❌ 벽에 부딪힘 페널티: 이동 명령 후 위치 변하지 않음 -5.0 보상
- ❌ 위험 구역 페널티: 위험 지역에서 IDLE이나 폭탄 설치 추가 페널티
- ❌ 적과 멀리 떨어진 곳 폭탄 페널티: 적과 거리가 멀 때 -10.0 보상

📈 효과

에이전트가 단기적인 안전만을 추구하여 발생하는 지역 최적화 문제를 완화를 시도하였으나 결과적으로 IDLE 패턴 반복

결론 및 향후 과제

🚩 프로젝트 성과와 의의

- ✔ 크레이지 아케이드와 유사한 2인 대전 환경에서 DQN과 PPO 강화학습 에이전트를 개발하고 분석하는 경험을 가지게 되었습니다.
- ✔ C++ 게임 서버와 Python 강화학습 에이전트 간의 TCP 소켓 통신 시스템을 구축했습니다.
- ✔ 알고리즘의 탐험 전략, 정책 표현 방식, 보상 설계가 에이전트의 최종 행동 양상에 미치는 영향을 심층적으로 분석하고 학문적 지식을 실체화할 수 있었습니다.

🏠 향후 과제 및 개선 방향

🎭 행동 마스킹 (Action Masking)

에이전트가 특정 상황에서 불가능한 행동을 선택하는 것을 방지하여 학습 효율성을 높입니다.

📈 커리큘럼 학습 (Curriculum Learning)

초기에는 간단한 목표부터 학습시키고 점진적으로 복잡한 전략을 익히도록 하여 학습 안정성을 높입니다.

🌡 온도 조절 탐험 (Temperature-controlled Exploration)

PPO 에이전트의 평가 시 결정론적 행동으로의 수렴 문제를 완화하기 위해 일정 부분 샘플링을 허용합니다.

느낀 점

기존에 알고 있던 구글 딥마인드의 벽돌깨기 라는 게임의 강화학습 실험이 생각보다 어려운 작업이었구나 라는 체감을 할 수 있었습니다. 사실 처음 이 과제를 계획하고 설계할 때에만 해도 “진짜 사람이 하는 것처럼 싸우게 만들 수 있겠지” 와 같은 자신감과 생각들이 있었는데 계속된 실패 이후로 무엇이 문제인지와 같은 고찰과 분석을 통해 내가 아직 강화학습 이라는 것에 대해 깊이 있게 이해하고 있지 못하다는 것을 인지하게 되었고 앞으로의 방향성을 세울 수 있게 되었습니다. 또한 이 과제의 문제를 해결하기 위해 방법들을 찾다보니 얕지만 더 넓은 지식을 얻게 되었습니다.